Primena genetskog programiranja u klasifikaciji spama

Milena Stojić

25. septembar 2021.

1 Uvod

Problem klasifikovanja nezeljene poste ili spama je problem koji od pocetka ere komunikacije putem elektronske poste privlaci veliku paznju. Osim sto nezeljene poruke pune nase sanduce i zatrpavaju potencijalno vazne poruke, spam poruke nanose veliku finansijsku stetu kompanijama [6], a mogu sadrzati i virus [4]. Prema jednoj studiji [13] cak preko 70% svih poslovnih mejlova je spam.

Veliki se napori ulazu da se napravi sto pouzdaniji klasifikator koji ce znati da prepozna i ukloni poruku koja je spam, ali koji u isto vreme nece pogresne mejlove klasifikovati kao spam.

Vecina poznatih algoritama klasifikacije poput SVM i neuronskih mreza je primenjeno na ovaj problem i svi su dali odlicne rezultate sa veoma malim greskama klasifikacije [9]. Pored standardnih algoritama klasifikacije postoji pokusaj razvoja klasifikatora i genetskim programiranjem [12].

U ovom pristupu klasifikator je bio u formi algebarskog izraza cija se vrednost racunala nad transformisanim vrednostima atributa i na osnovu te vrednosti izraza klasifikovala instanca. Algoritam je sam davao malo losije rezultate od standardnih algoritama klasifikacije, ali ansambl ovih klasifikatora je davao bolje rezultate od polovine postojecih algoritama.

Genetsko programiranje (skraceno *GP*) je metaheuristika koja je, poput genetskih algoritama (skraceno *GA*), inspirisana evolucijom. [2]. Pronalazi primene u masinskom ucenju i cesto se koristi kao alat u preprocesiranju podataka. [3] Mi cemo u ovom radu direktno konstruisati stabla odlucivanja, to jest klasifikatore, genetskim programiranjem, probati za moguce vrednosti parametara i potom uporediti dobijene rezultate sa rezultatima iz prethodnih istrazivanja.

U poglavlju 2 cemo dati detaljniji opis opsteg algoritma genetskog programiranja, a u poglavlju 3 konkretan opis naseg pristupa. Eksperimentalni rezultati sa uporedjivanjem sa postojecim rezultatima ce biti u 4 i u 5 zakljucak sa razmatranjem mogucih nacina daljeg unapredjivanja.

2 Genetsko programiranje

Zamisao genetskog programiranja je bila evolucija racunarskih programa koji za korisnika obavljaju odredjeno izracunavanje. [2] Kao i kod svih ostalih evolutivnih algoritama, inspirisanih Darvinovom teorijom evolucije, i u genetskom programiranju imamo koncepte kao sto su selekcija, ukrstanje i mutacija.

Prva istrazivanja koja su isla u tom pravcu su zapocela pocetkom 80-ih godina proslog veka. [2] Neki od doprinosa iz tog perioda su Smitov sistem ucenja zasnovan na genetskim algoritmima [11] (koji je autoru bio tema doktorske disertacije) i Forsitov kompjuterski paket za generisanje pravila odlucivanja u oblasti forenzike [7]. Jedno od prvih vaznih publikacija na temu genetskog programiranja je "Genetsko programiranje - o programiranju racunara prirodnom selekcijom"[8] ciji je autor J. Koza, profesor univerziteta Stenford koji se medju prvima bavio istrazivanjima na temu genetickog programiranja i koji ima velike naucne doprinose u ovoj oblasti. Danas GP ima raznovrsne primene u najrazlicitijim oblastima, od problema masinskog ucenja, kao sto je, recimo, predvidjanje cena akcija, do raznih primena u inzenjerstvu. [10]

2.1 Opsti princip

Programi (bilo kakve vrste) se najprirodnije predstavljaju hijerarhijskom, drvolikom reprezentacijom. Tako da su jedinke u populaciji (koje predstavljaju programe) predstavljene u formi drveta. Za razliku od jedinki u genetskim algoritmima koje se predstavljaju linearnom strukturom fiksne velicine. U drvetu obicno jasno razlikujemo dva tipa cvora:

- **unutrasnji (neterminalni) cvorovi** - obicno predstavljaju neke funkcije ili operacije koje se primenjuju u toku izracunavanja
- **terminalni cvorovi (u listovima)** - obicno predstavljaju vrednosti koje ucestvuju u izracunavanjima. Deo terminalnih cvorova moze biti namenjen ulaznim podacima (koji ce ucestvovati u izracunavanju), a u ostalim konstantne vrednosti koje ucestvuju u svakom izracunavanju.

U nasem slucaju u listovima ce biti klase koje se mogu dobiti izracunavanjem. (dakle izlazne vrednosti izracunavanja)

Selekcija u GP-u je obicno ruletska. (srazmerna fitnesu) Pri formiranju jedinke iz nove generacije obicno se slucajno bira da li ce se izvrsiti mutiranje odabrane jedinke (sa veoma malom verovatnocom, obicno reda ~ 0.05) ili ukrstanje dve odabrane jedinke iz tekuce populacije. Odredjen broj jedinki sa najboljom vrednoscu fitnes funkcije se moze iz tekuce generacije direktno prenositi u narednu kao i kod genetskih algoritama. (koncept elitizma)
Mutacija kao slucajna promena u stablu se moze obavljati na razlicite nacine. Ukrstanje se radi razmenom podstabala izmedju jedinki koje se ukrstaju.

3 Opis moje metode

Posto u resavanju koristimo genetsko programiranje, potrebno je da objasnimo sta ce nam biti jedinke i kako ce tacno biti predstavljene. Takodje je potrebno da objasnimo sta ce predstavljati fitnes funkciju i na koji nacin je izracunavamo.

Jedinke ce nam biti pojedinacni klasifikatori koji ce biti stabla odlucivanja. U stablima odlucivanja terminalni cvorovi su atributi, a u terminalnim cvorovima su predvidjene klase.

Klasifikacija instance se vrsi na sledeci nacin: polazi se od korena stabla odlucivanja, ispituje se vrednost atributa iz korena u toj instanci i u zavisnosti od te vrednosti (tacan uslov zavisnosti je obicno definisan u samom cvoru ili na neki drugi nacin) nastavlja se ispitivanje u levom ili u desnom podstablu. I tako radimo za svaki unutrasnji cvor (i atribut u njemu) sve dok ne stignemo do terminalnog cvora. Instanci dodeljujemo onu klasu koja se nalazi u terminalnom cvoru u koji smo stigli.

3.1 Implementacija jedinki

3.1.1 Korisceni atributi - geni

Atributi koje cemo koristiti u neterminalnim cvorovima stabala odlucivanja su preuzeta iz skupa atributa iz *Spam-base Data Set*-a [1]. Skup podataka se sastoji od 4601 instanci koje predstavljaju mejlove. U skupu atributi su (ne racunujaci ciljni atribut) reci, slova, kao i prosesna duzina sekvenci uzastopnih velikih slova, najveca duzina sekvence uzastopnih velikih slova i ukupna duzina svih sekvenci uzastopnih velikih slova. Za nas su u tom skupu podataka vec izracunate frekvencije reci i slova, zbog cega je taj skup podataka zgodan. Ne moramo da se bavimo *textmining*-om koji nije fokus ovog rada.

Od tih atributa koristili smo deo atributi cija je prosecna vrednost veca za mejlove koji su spam. Ideja je bila da se koriste atributi cije vece vrednosti su obicno karakteristicne za spam mejlove.

3.1.2 Sirova implementacija stabla odlucivanja

Stabla odlucivanja smo interno implementirali nizovima fiksne duzine. Definisali smo minimalnu i maksimalnu mogucu dubinu stabla. Maksimalan broj cvorova u stablu dubine $d >= 1$ je

$$1 + 2^1 + 2^2 + ... + 2^d = \frac{2^{d+1} - 1}{2 - 1} = 2^{d+1} - 1$$

tako da su nam nizovi interno uvek duzine

$$2^{najveca\_dubina} - 1$$

. U zavisnosti od dubine stabala koristicemo odredjene delove niza ili ceo niz. Clanovi niza koji se ne koriste imaju nedefinisanu (*None*) vrednost.

Ako bismo jednostavno cuvali atribute u stablu, takva stabla bi dobro radila u klasifikaciji, ali ne bi bila pogodna za operatore ukrstanja. Na primer, desavalo bi se da cesto pri ukrstanju dobijamo stablo u kome bismo na putu od korena do nekog lista imali vise puta ponovljen atribut. Drugim recima, bila bi vise puta ispitivana vrednost istog atributa. Da bismo ovo izbegli, moramo da drugacije kodiramo atribute u stablu. Tako da i dalje imamo ispravna stabla odlucivanja, ali i da ukrstanjem takodje dobijamo ispravna stabla odlucivanja.

Da bismo prevazisli ovaj problem u kodiranju, iskoriscena je (samo) pocetna ideja iz jednog konferencijskog clanka koji sam citala radeci na drugom projektu. [5] Umesto da koristimo direktno atribute, koristicemo njihove indekse u *trenutnom nizu atributa*. Naime, u korenu cemo cuvati indeks atributa u (celom) nizu atributa. U neterminalnom cvoru na nekoj dubini $d >= 1$ cemo cuvati indeks atributa u nizu svih atributa iz koga su uklonjeni atributi u precima cvora. Ideja je jasnije prikazana na slici ispod.

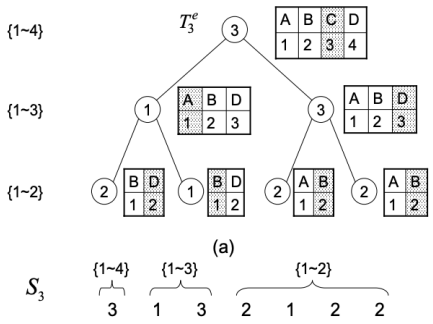

Prikaz kodiranja stabla odlucivanja [5]

U cvoru dubini d mogu biti vrednosti indeksa od 0 do $(n-1)-d$, gde je n ukupan broj atributa koji se koristi u izgradnji stabla.

3.1.3 Omotac klasa jedinke

Objekat klase koja implementira jedinke je sacinjen od stabla odlucivanja i vrednosti fitnes funkcije. Za svaku jedinku znamo da izracunamo vrednost fitnes funkcije. Dva stabla se uporedjuju po vrednosti fitnes funkcije.

3.2 Fitnes funkcija

Nama je cilj da ovim algoritmom dobijemo stablo koje ce imati sto bolju klasifikacije. Tako da nam fitnes funkcija moze biti neka od mera kvaliteta klasifikacije ili kombinacija vise aspekata kvaliteta klasifikacije. (linearna kombinacija ili bilo kakva drugacija funkcija vise merila klasifikacije)
Ovde ce nam fitnes funkcija biti tacnost (eng. *accuracy*). Ta mera predstavlja udeo dobro klasifikovanih instanci, to jest:

$$accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

3.3 Inicijalizacija populacije

Populacija se slucajno generise ogranicenim pristupom. To znaci da dubina stabala moze da varira izmedju minimalne i maksimalne vrednosti. Pri samom kreiranju jedne instance stabla njen sadrzaj se unapred slucajno generise. Tako da je dovoljno da samo kreiramo zeljeni broj stabala i imamo spremnu pocetnu populaciju.

3.4 Selekcija

Selekcija jedinki za ukrstanje ili mutaciju je ruletska ili fitnes srazmerna selekcija. Bice primenjen i elitizam, jer ako dodjemo do jako dobrih jedinki, ne zelimo da ih izgubimo.

3.5 Operatori ukrstanja i mutacije

Ukrstanje je razmena podstabala izmedju dve jedinke, kao u svakom GP algoritmu.
Operatorom mutacije mi menjamo slucajno izabrani cvor (terminalni ili neterminalni) slucajno izabranom vrednoscu odgovarajuceg tipa.

3.6 Dodatno

Posle izvrsavanja svih iteracija, osim evaluacije klasifikacije najbolje jedinke na test podacima ispitivali smo kakvu klasifikaciju nam daje i ansambl odredjenog broja najboljih jedinki. Ovaj pristup je koriscen pri poboljsavanju metode genetskog programiranja u [12] i dao je dobre rezultate.

4 Eksperimentalni rezultati

Tehnicke karakteristike i okruzenje

Projekat je implementiran u programskom jeziku Python. Od biblioteka koriscene su biblioteke *Numpy* (za generisanje pseudoslucajnih brojeva i nekoliko matematickih funkcija), *Pandas* (za ucitavanje i rad sa podacima), modul *metrics* i jos jedan metod iz *Scikit-learn* biblioteke (za evaluaciju kvaliteta klasifikovanja) i biblioteka *Matplotlib* za vizualizaciju.

Tokom razvoja koriscen je skup podataka *Spambase Data set* [1]. Pre formiranja populacije delili smo ga na trening i test podatke. Pre izvrsavanja genetskog algoritma razmatrali bismo trening podatke. (to jest, prosecne vrednosti atributa svih instanci koje su spam iz tog podskupa podataka bismo iskoristili za izgradnju stabla odlucivanja)
Na kraju, posle izvrsavanja celog GP-a bismo vrsili evaluaciju na osnovu test podataka.

Karakteristike okruzenja:

- Hardver: 2,4 GHz *Quad-Core Intel Core i5* (4 jezgara, u isto vreme je paralelno izvrsavano vise skriptova sa razlicitim parametrima), RAM: 8 GB
- Operativni sistem: *Mac OS 11.5.2*
- Razvojno okruzenje: *PyCharm*
- Interpreter: *Python 3.9*

4.1 Dobijeni rezultati

U tabeli se mogu videti dobijeni eksperimentalni rezultati dobijeni za razlicite vrednosti parametara. Pokazuje se da je broj jedinki u populaciji najvazniji parametar. Sto je veca populacija, imacemo bolju klasifikaciju.

Najbolje bi bilo kada bismo uz veliki broj jedinki u populaciji imali i veliki broj iteracija. Medjutim, ako zbog vremenskih ili hardverskih ogranicenja moramo da ogranicimo vrednost jednog od parametara, za kvalitet klasifikacije se vise isplati da smanjimo broj iteracija. Kao sto se moze videti u tabeli, za cak vrlo mali broj iteracija na velikoj populaciji smo dobijali znatno bolje rezultate nego uz vise iteracija na manjoj populaciji.

TODO

iteracije, n, pm, elitizam	mere kvaliteta klasifikacije		
parametri	**tacnost**	**preciznost**	**f-mera**

4.2 Poredjenje sa postojecim rezultatima

Iako postoji rad [9] koji se bavi poredjenjem razlicitih klasifikatora spama na istom skupu podataka koji je koriscen i u ovom radu, koriscene su drugacije mere kvaliteta u evaluaciji. (izuzev za najbolji klasifikator, slucajnu sumu, za koju su dodate dve mere koje su koriscene u ovom radu)

Razmatracemo rezultate iz [12]. // **TODO** U ovom radu je radjeno na dva skupa podataka. Mi cemo upoređjivati sa vrednostima dobijenim na skupu podataka na kome su generalno dobijeni losiji rezultati.

U tabeli su dati rezultati za GP algoritme i za jos dva tipa klasifikatora. **TODO**

Klasifikator	Tacnost	F-mera
GP	0.848	0.848
Unapredjeni GP (ansambl)	0.941	0.941
SVM	0.938	0.938
Nasumicna suma	0.939	0.939

Mozemo videti da je po meri tacnosti nas pristup blizak tacnosti GP algoritma. Trebalo bi jos pomenuti da su u ovom radu, za razliku od naseg, na efektniji nacin birani atributi koji ucestvuju u klasifikaciji. Kada bismo imali bolje gene, imali bismo i bolju klasifikaciju. U ovom radu se takodje mera kvaliteta tacnost koristi kao fitnes funkcija.

5 Zakljucak

U ovom radu smo jednim drugacijim pristupom pokusali da implementiramo algoritam klasifikacije spama. Fokus je bio na samom principu genetskog programiranja, dok se u kvalitet preprocesiranja podataka nije duboko ulazilo. Dobili smo rezultat koji po tacnosti nije blizu pristupima poput SVM ili slucajne sume, ali jeste blizak rezultatu dobijenom standardnim GP pristupom iz literature.

Ovo nas moze ohrabriti da daljim radom i poboljsavanjem pokusamo da dobijemo jos bolje rezultate. Narocito ako posvetimo vise paznje izboru najboljeg podskupa atributa (eng. *feature selection*) i izbora nacina na koji da ispitujemo vrednost tog atributa u stablu.

Jos jedan nacin da unapredimo nas algoritam je da pronadjemo pogodniji izraz za fitnes funkciju. U kome bi, pored tacnosti takodje figurisale i druge bitne mere kvaliteta klasifikacije. U ovom slucaju, na primer, to bi mogao da bude broj lazno pozitivnih u imeniocu izraza za racunanje fitnes funkcije.

Literatura

[1] UCI machine learning repository – Spambase Data Set, 1999. http://archive.ics.uci.edu/ml/datasets/Spambase.

[2] Michael Affenzeller, Stephan Winkler, Stefan Wagner, and Andreas Beham. *Genetic Algorithms and Genetic Programming: Modern Concepts and Practical Applications*. Chapman Hall/CRC, 1st edition, 2009.

[3] Qurrat Ul Ain, Bing Xue, Harith Al-Sahaf, and Mengjie Zhang. Genetic programming for feature selection and feature construction in skin cancer image classification. In *Pacific rim international conference on artificial intelligence*, pages 732–745. Springer, 2018.

[4] Mamoun Alazab and Roderic Broadhurst. Spam and criminal activity. *Trends and issues in crime and criminal justice*, (526):1–20, 2016.

[5] Sung-Hyuk Cha and Charles Tappert. Constructing Binary Decision Trees using Genetic Algorithms. page 3, 2008.

[6] V Christina, S Karpagavalli, and G Suganya. A study on email spam filtering techniques. *International Journal of Computer Applications*, 12(1):0975–8887, 2010.

[7] R FORSYTH. Beagle—a darwinian approach to pattern recognition. *Kybernetes*, Vol. 10(No. 3):pp. 159–166, 1981.

[8] John R Koza and John R Koza. *Genetic programming: on the programming of computers by means of natural selection*, volume 1. MIT press, 1992.

[9] R. Kumar, G. Poonkuzhali, and Sudhakar Pandiarajan. Comparative study on email spam classifier using data mining techniques. *Lecture Notes in Engineering and Computer Science*, 2195:539–544, 03 2012.

[10] Michael O'Neill, Leonardo Vanneschi, Steven Gustafson, Anna Isabel Esparcia Alcázar, Ivanoe De Falco, Antonio Della Cioppa, and Ernesto Tarantino. *Genetic Programming: 11th European Conference, EuroGP 2008, Naples, Italy, March 26-28, 2008, Proceedings*, volume 4971. Springer, 2008.

[11] S. F. Smith. *A Learning System Based on Genetic Adaptive Algorithms*. PhD thesis, University of Pittsburgh, 1980.

[12] Shrawan Trivedi and Shubhamoy Dey. An enhanced genetic programming approach for detecting unsolicited emails. pages 1153–1160, 12 2013.

[13] Bo Yu and Zong-ben Xu. A comparative study for content-based dynamic spam classification using four machine learning algorithms. *Knowledge-Based Systems*, 21(4):355–362, 2008.